



Centro Universitário de Brasília - CEUB
Diretoria de Educação a Distância - DIREAD
Curso Superior de Tecnologia em Banco de Dados

SISTEMATIZAÇÃO: Ciência de Dados II - Turma B - 0726

DOUGLAS AREND LEÃO

RA: 72500862

QUALIDADE DO AR EM PEQUIM: ESTIMATIVA DE PM2.5 E IDENTIFICAÇÃO DE PERFIS DE POLUIÇÃO COM APACHE SPARK

Professor: Romes Heriberto Pires de Araujo

BRASÍLIA-DF

2026

RESUMO EXECUTIVO

O presente trabalho aplica o processo de Descoberta de Conhecimento em Bases de Dados (KDD) à análise de 420.768 registros horários de qualidade do ar coletados em 12 estações de Pequim entre março de 2013 e fevereiro de 2017. O objetivo é investigar padrões temporais e espaciais de PM2.5, comparar modelos capazes de estimar essa concentração a partir de outras medições disponíveis no mesmo horário e identificar perfis recorrentes de poluição e condições meteorológicas. O processamento foi realizado com Apache Spark, abrangendo ingestão, validação, preparação, consultas Spark SQL, regressão supervisionada e clusterização.

A análise exploratória identificou maior média de PM2.5 em Dongsi (86,19 $\mu\text{g}/\text{m}^3$) e menor em Dingling (65,99 $\mu\text{g}/\text{m}^3$). Dezembro apresentou a maior média mensal histórica (104,58 $\mu\text{g}/\text{m}^3$), enquanto agosto apresentou a menor (53,47 $\mu\text{g}/\text{m}^3$). A maior média horária ocorreu às 22h (88,89 $\mu\text{g}/\text{m}^3$). Registros com vento abaixo de 1 m/s tiveram média de 102,30 $\mu\text{g}/\text{m}^3$, contra 36,16 $\mu\text{g}/\text{m}^3$ quando a velocidade foi igual ou superior a 3 m/s. Essas comparações são descritivas e não demonstram causalidade.

Na modelagem supervisionada, a Random Forest apresentou o menor RMSE na validação e foi aplicada uma única vez ao teste temporal reservado. No teste, obteve RMSE de 26,6613 $\mu\text{g}/\text{m}^3$, MAE de 16,2067 $\mu\text{g}/\text{m}^3$ e R^2 de 0,8962, sem estimativas negativas. A solução realiza uma estimativa contemporânea de PM2.5 e não uma previsão para horas ou dias futuros.

A clusterização selecionou dois perfis. O Grupo 1 reuniu 47,68% dos registros e apresentou maiores concentrações médias de PM2.5, PM10, SO2, NO2 e CO, associadas a menor temperatura, maior pressão e menor O3. O Grupo 2 reuniu 52,32% e apresentou o padrão aproximadamente inverso. Todas as estações foram representadas nos dois grupos, evidenciando que os clusters não correspondem apenas a uma divisão geográfica.

Conclui-se que o fluxo implementado oferece subsídios para investigação e monitoramento ambiental, desde que os resultados sejam interpretados dentro do recorte histórico e das limitações metodológicas. Recomenda-se validar o modelo em dados mais recentes e em outras localidades, investigar os mecanismos de ausência e incorporar atributos defasados caso o objetivo futuro seja previsão temporal.

Palavras-chave: Qualidade do Ar. PM2.5. Apache Spark. Random Forest. K-Means. Ciência de Dados.

Repositório: github.com/douglasarend/sistematizacao-ciencia-dados-ii

Fonte: UCI Machine Learning Repository

ABSTRACT

This paper applies the Knowledge Discovery in Databases (KDD) process to 420,768 hourly air-quality records collected from 12 monitoring stations in Beijing between March 2013 and February 2017. The goals are to investigate temporal and spatial PM_{2.5} patterns, compare models that estimate PM_{2.5} from other measurements available at the same hour, and identify recurring pollution and weather profiles. Apache Spark was used for ingestion, validation, preprocessing, Spark SQL queries, supervised regression, and clustering.

Exploratory analysis found the highest average PM_{2.5} concentration at Dongsi (86.19 $\mu\text{g}/\text{m}^3$) and the lowest at Dingling (65.99 $\mu\text{g}/\text{m}^3$). December had the highest historical monthly average (104.58 $\mu\text{g}/\text{m}^3$), while August had the lowest (53.47 $\mu\text{g}/\text{m}^3$). Observations with wind speeds below 1 m/s averaged 102.30 $\mu\text{g}/\text{m}^3$, compared with 36.16 $\mu\text{g}/\text{m}^3$ when wind speed was at least 3 m/s. These comparisons are descriptive and do not establish causality.

Random Forest achieved the lowest validation RMSE and was evaluated once on the reserved temporal test set. It obtained an RMSE of 26.6613 $\mu\text{g}/\text{m}^3$, an MAE of 16.2067 $\mu\text{g}/\text{m}^3$, and an R^2 of 0.8962, with no negative estimates. K-Means selected two interpretable profiles: one with higher average concentrations of primary pollutants and colder conditions, and another with lower levels of those pollutants, warmer conditions, and higher ozone. The results support environmental investigation and monitoring, but require external validation before use in other periods or locations.

Keywords: Air Quality. PM_{2.5}. Apache Spark. Random Forest. K-Means. Data Science.

SUMÁRIO

1 INTRODUÇÃO	4
1.1 Contexto e problema	4
1.2 Objetivos	4
1.2.1 Objetivo geral	4
1.2.2 Objetivos específicos	4
1.3 Delimitação	4
1.4 Reprodutibilidade e links	4
2 DATASET E PREPARAÇÃO DOS DADOS	5
2.1 Caracterização do dataset	5
2.2 Processo de KDD	5
2.3 Qualidade e tratamento	5
2.4 Prevenção de vazamento de dados	6
3 ANÁLISE EXPLORATÓRIA COM SPARK SQL	7
3.1 Diferenças entre estações	7
3.2 Perfis mensal e horário	8
3.3 Associação com velocidade do vento	8
3.4 Evolução histórica e disponibilidade	8
4 MODELAGEM SUPERVISIONADA	9
4.1 Problema e modelos candidatos	9
4.2 Seleção e avaliação final	10
5 MODELAGEM DESCRITIVA COM K-MEANS	11
5.1 Preparação e seleção de K	11
5.2 Perfil dos clusters	12
5.3 Distribuição entre estações	13
6 RECOMENDAÇÕES, LIMITAÇÕES E TRABALHOS FUTUROS	14
6.1 Recomendações	14
6.2 Limitações	14
6.3 Trabalhos futuros	14
7 CONCLUSÃO	15
8 REFERÊNCIAS	16
8.1 Links do projeto	16

1 INTRODUÇÃO

1.1 Contexto e problema

A qualidade do ar é influenciada por emissões, condições meteorológicas e variações temporais e espaciais. Bases horárias de múltiplas estações permitem investigar esses padrões e testar métodos de aprendizado de máquina, mas exigem integração, limpeza, transformação e interpretação cuidadosas.

O projeto foi concebido como um estudo de caso de consultoria ambiental. O problema central consiste em transformar uma base histórica de grande volume em informações úteis para investigação e monitoramento, sem confundir associação estatística com causalidade ou extrapolar os resultados para contextos não avaliados.

1.2 Objetivos

1.2.1 Objetivo geral

Aplicar o processo de KDD a dados de qualidade do ar utilizando Apache Spark, integrando análise exploratória, modelagem supervisionada e clusterização.

1.2.2 Objetivos específicos

- Investigar padrões temporais e espaciais nas concentrações de PM2.5.
- Comparar modelos de famílias diferentes, incluindo um ensemble, para estimar PM2.5 no mesmo horário das demais medições.
- Avaliar o modelo selecionado em um período temporal reservado.
- Identificar perfis recorrentes de poluição e condições meteorológicas com K-Means.
- Registrar limitações, aplicações possíveis e recomendações.

1.3 Delimitação

A modelagem supervisionada realiza uma estimativa contemporânea. Ela pressupõe que outros poluentes e variáveis meteorológicas estejam disponíveis no horário da estimativa. O estudo não prevê a concentração em um horário futuro, não demonstra causalidade e não constitui um sistema operacional ou uma classificação oficial de risco à saúde.

1.4 Reprodutibilidade e links

Repositório público: <https://github.com/douglasarend/sistematizacao-ciencia-dados-ii>

Fonte original: Beijing Multi-Site Air Quality - UCI

DOI: <https://doi.org/10.24432/C5RK5G>

2 DATASET E PREPARAÇÃO DOS DADOS

2.1 Caracterização do dataset

Característica	Descrição
Fonte	Beijing Multi-Site Air Quality - UCI
Período	01/03/2013 a 28/02/2017
Granularidade	Medições horárias
Volume	420.768 registros e 18 colunas originais
Cobertura	12 estações de monitoramento
Variável-alvo	PM2.5

O notebook baixa os 12 arquivos diretamente da fonte oficial, valida o pacote e registra seu hash SHA-256. O dataset bruto não precisa ser armazenado no repositório.

2.2 Processo de KDD

Etapa	Procedimento aplicado
Seleção e integração	Download, validação e ingestão dos arquivos com Spark DataFrames.
Pré-processamento	Duplicatas, datas, chaves, valores inválidos, ausências e extremos.
Transformação	Data/hora, atributos temporais e cíclicos, codificação e vetores.
Mineração	Spark SQL, Regressão Linear, Random Forest e K-Means.
Interpretação	Métricas, gráficos, perfis, limitações e recomendações.

2.3 Qualidade e tratamento

A validação não encontrou duplicatas idênticas, datas ou identificadores inválidos, medições conflitantes para a mesma estação e horário, nem valores numéricos inválidos segundo as regras implementadas. A base exploratória preservou os 420.768 registros.

Foram identificadas 20.701 ausências de CO (4,92%), 13.277 de O3 (3,16%), 12.116 de NO2 (2,88%), 9.021 de SO2 (2,14%), 8.739 de PM2.5 (2,08%) e 6.449 de PM10 (1,53%). A base supervisionada utilizou os 412.029 registros com PM2.5 observado.

Valores extremos foram diagnosticados pelo intervalo interquartil e mantidos. Para precipitação, Q1 e Q3 iguais a zero fazem com que toda medição positiva seja sinalizada pela regra, razão pela qual essa marcação não foi interpretada como erro.

2.4 Prevenção de vazamento de dados

Na regressão, a imputação foi ajustada somente no treinamento e depois aplicada à validação e ao teste. O próprio PM2.5 não foi utilizado como atributo de entrada. O teste permaneceu isolado do ajuste e da seleção do modelo.

Conjunto	Período	Registros	Finalidade
Treinamento	mar/2013 a fev/2015	205.989	Ajuste
Validação	mar/2015 a fev/2016	103.287	Seleção
Teste	mar/2016 a fev/2017	102.753	Avaliação final

3 ANÁLISE EXPLORATÓRIA COM SPARK SQL

Seis consultas Spark SQL investigaram diferenças entre estações, meses, horários, velocidade do vento, anos civis completos e disponibilidade das medições. O Pandas recebeu apenas pequenas tabelas agregadas para produção dos gráficos.

3.1 Diferenças entre estações

Dongsi apresentou a maior concentração média de PM2.5, com 86,19 $\mu\text{g}/\text{m}^3$, enquanto Dingling apresentou a menor, com 65,99 $\mu\text{g}/\text{m}^3$. A diferença de 20,20 $\mu\text{g}/\text{m}^3$ pode orientar investigações locais, mas não identifica as causas do contraste.




Figura 1 - Concentração média de PM2.5 por estação.

3.2 Perfis mensal e horário

Dezembro apresentou a maior média mensal histórica, com $104,58 \mu\text{g}/\text{m}^3$, e agosto a menor, com $53,47 \mu\text{g}/\text{m}^3$. No perfil horário, a maior média ocorreu às 22h, com $88,89 \mu\text{g}/\text{m}^3$, e a menor às 7h, com $73,27 \mu\text{g}/\text{m}^3$. As agregações combinam diferentes anos e estações e não constituem previsão futura.

3.3 Associação com velocidade do vento

A média de PM_{2.5} foi de $102,30 \mu\text{g}/\text{m}^3$ quando a velocidade do vento ficou abaixo de 1 m/s, $79,81 \mu\text{g}/\text{m}^3$ entre 1 e menos de 3 m/s e $36,16 \mu\text{g}/\text{m}^3$ quando a velocidade foi igual ou superior a 3 m/s. O resultado sugere associação, mas não controla estação, época do ano ou outras variáveis.




Figura 2 - PM_{2.5} médio por faixa de velocidade do vento.

3.4 Evolução histórica e disponibilidade

Entre os anos civis completos, a média foi de $85,58 \mu\text{g}/\text{m}^3$ em 2014, $79,63 \mu\text{g}/\text{m}^3$ em 2015 e $71,93 \mu\text{g}/\text{m}^3$ em 2016. A diferença de $-13,65 \mu\text{g}/\text{m}^3$ descreve o intervalo estudado, mas não comprova uma tendência permanente. Huairou apresentou a maior ausência de PM_{2.5} (2,72%) e Dongsi a maior ausência de CO (9,12%).

4 MODELAGEM SUPERVISIONADA

4.1 Problema e modelos candidatos

O objetivo foi estimar PM_{2.5} com outros poluentes, variáveis meteorológicas, atributos temporais, estação e direção do vento disponíveis no mesmo horário. Foram comparadas uma referência pela média do treinamento, Regressão Linear com regularização L2 e Random Forest.

A Random Forest foi configurada com 40 árvores, profundidade máxima 8, mínimo de 5 observações por nó, subamostragem de 0,8 e semente 42. O critério definido previamente para seleção foi o menor RMSE de validação.

Modelo / conjunto	RMSE	MAE	R ²	Negativas
Referência / validação	82,6044	61,0146	-0,0177	0,00%
Regressão Linear / validação	30,6096	19,7523	0,8603	9,44%
Random Forest / validação	29,3306	16,3009	0,8717	0,00%
Random Forest / teste	26,6613	16,2067	0,8962	0,00%




Figura 3 - Comparação do RMSE dos modelos na validação.

4.2 Seleção e avaliação final

A Random Forest apresentou o menor RMSE na validação e foi selecionada antes do acesso ao teste. A Regressão Linear produziu estimativas negativas em 9,44% dos registros de validação, comportamento incompatível com a natureza da concentração.

No teste temporal, a Random Forest alcançou RMSE de 26,6613 $\mu\text{g}/\text{m}^3$, MAE de 16,2067 $\mu\text{g}/\text{m}^3$ e R^2 de 0,8962, sem previsões negativas. O RMSE foi 9,10% inferior ao da validação, sem evidência de degradação no período posterior reservado.




Figura 4 - RMSE da Random Forest na validação e no teste.

O R^2 não representa uma porcentagem de acertos. Ele mede a proporção da variabilidade do alvo explicada pelo modelo em relação a uma referência baseada na média. O desempenho não está validado para outras cidades ou períodos.

5 MODELAGEM DESCRITIVA COM K-MEANS

5.1 Preparação e seleção de K

A clusterização utilizou seis poluentes e cinco variáveis meteorológicas. Ausências foram preenchidas pela mediana e os atributos padronizados. Valores de K entre 2 e 6 foram avaliados em uma amostra reprodutível de 105.282 registros.

K	Silhueta na amostra
2	0,4641
3	0,4025
4	0,3290
5	0,3092
6	0,3008




Figura 5 - Seleção de K pelo coeficiente de silhueta.

K = 2 apresentou a maior silhueta na amostra. O modelo definitivo treinado nos 420.768 registros obteve silhueta de 0,3683. A redução indica maior sobreposição na base completa e exige interpretação moderada.

5.2 Perfil dos clusters

Indicador	Grupo 1	Grupo 2
Registros	200.631 (47,68%)	220.137 (52,32%)
PM2.5 médio	100,80 µg/m³	60,43 µg/m³
PM10 médio	126,77 µg/m³	84,29 µg/m³
SO2 médio	24,65 µg/m³	7,73 µg/m³
NO2 médio	65,58 µg/m³	36,96 µg/m³
CO médio	1.686,22 µg/m³	813,09 µg/m³
O3 médio	27,55 µg/m³	84,42 µg/m³
Temperatura	3,69 °C	22,52 °C
Pressão	1.018,85 hPa	1.003,36 hPa

O Grupo 1 representa condições mais frias, de maior pressão e com maiores níveis médios de poluentes primários. O Grupo 2 apresenta temperaturas mais altas, menor pressão, menores níveis desses poluentes e O3 mais elevado. Portanto, os grupos não devem ser reduzidos a rótulos de 'poluído' e 'não poluído'.




Figura 6 - Perfil padronizado dos centroides do K-Means.

5.3 Distribuição entre estações

Wanliu foi a estação mais frequente no Grupo 1, com 17.856 registros (8,90% do grupo). Dingling foi a mais frequente no Grupo 2, com 21.279 registros (9,67%). Dentro das estações, Dingling apresentou 60,69% dos registros no Grupo 2, seguida por Huairou (58,14%) e Changping (56,00%).

Oito das 12 estações apresentaram entre 48% e 52% de seus registros no Grupo 1. Todas possuem participação substancial nos dois clusters, o que mostra que os perfis não são meros substitutos da localização geográfica.




Figura 7 - Distribuição dos clusters dentro de cada estação.

6 RECOMENDAÇÕES, LIMITAÇÕES E TRABALHOS FUTUROS

6.1 Recomendações

- Priorizar investigações em estações, meses e horários com maiores concentrações históricas.
- Considerar condições de vento no planejamento do monitoramento, sem interpretar a associação como causalidade.
- Investigar as ausências de PM_{2.5} em Huairou e de CO em Dongsi.
- Utilizar a Random Forest como referência para estimativas contemporâneas quando as medições auxiliares estiverem disponíveis.
- Acompanhar separadamente episódios compatíveis com os dois perfis, pois o maior O₃ não coincide com os maiores níveis dos demais poluentes.

6.2 Limitações

- Os dados são históricos e pertencem a uma única região.
- As comparações exploratórias não demonstram causalidade nem representam exposição individual.
- A modelagem supervisionada não prevê PM_{2.5} futuro e pressupõe disponibilidade das medições auxiliares.
- A exploração examinou toda a base; o teste temporal não equivale a uma validação externa completamente inédita.
- Não houve busca exaustiva de hiperparâmetros nem validação em outras cidades.
- $K = 2$ foi o melhor valor apenas no intervalo testado, e a silhueta final indica sobreposição entre grupos.
- Os clusters não são categorias oficiais de qualidade do ar ou de risco à saúde.

6.3 Trabalhos futuros

Recomenda-se testar o modelo em dados mais recentes e de outras localidades, investigar mecanismos de ausência, ampliar a busca de hiperparâmetros e incluir atributos defasados no tempo caso o objetivo seja construir previsão futura. Também seria útil avaliar incerteza preditiva e mudanças de distribuição ao longo do tempo.

7 CONCLUSÃO

O projeto demonstrou a aplicação integrada do processo de KDD em uma base com mais de 400 mil registros. O Apache Spark permitiu organizar preparação, consultas SQL, análise exploratória, regressão e clusterização em um fluxo reproduzível.

A análise exploratória identificou diferenças relevantes entre estações, meses, horários e condições de vento. Esses resultados oferecem pontos de partida para investigação, mas não devem ser interpretados como relações causais ou como representação direta da exposição individual.

A Random Forest apresentou o melhor desempenho entre os modelos candidatos e manteve resultados consistentes no teste temporal. O K-Means complementou a análise ao revelar dois perfis ambientais distintos, sem reduzi-los a diferenças geográficas entre estações.

Em conjunto, os resultados oferecem subsídios para monitoramento e tomada de decisão dentro do contexto histórico estudado. A utilização fora desse recorte depende de validação externa, atualização dos dados e avaliação contínua das limitações metodológicas.

8 REFERÊNCIAS

APACHE SOFTWARE FOUNDATION. Apache Spark Documentation. Disponível em: <https://spark.apache.org/docs/latest/>. Acesso em: 20 set. 2026.

CHAMBERS, Bill; ZAHARIA, Matei. Spark: The Definitive Guide: Big Data Processing Made Simple. Sebastopol: O'Reilly Media, 2018.

CHEN, Song. Beijing Multi-Site Air Quality [Dataset]. UCI Machine Learning Repository, 2017. DOI: 10.24432/C5RK5G.

HAN, Jiawei; KAMBER, Micheline; PEI, Jian. Data Mining: Concepts and Techniques. 3. ed. Waltham: Morgan Kaufmann, 2011.

8.1 Links do projeto

Repositório	https://github.com/douglasarend/sistematizacao-ciencia-dados-ii
Dataset	https://archive.ics.uci.edu/dataset/501/beijing+multi+site+air+quality+data
DOI	https://doi.org/10.24432/C5RK5G

O notebook principal contém os códigos, as saídas registradas, as tabelas e os resultados utilizados neste relatório.